

NF1 — Presentación y viabilidad del proyecto

C088. Proyecto de Inteligencia Artificial y Big Data

Título provisional

Piriscopes: sistema de estimación diaria de riesgo de incendio forestal por municipio.

Elevator pitch

Los índices meteorológicos existentes aportan información fundamental sobre condiciones ambientales, pero no incorporan modelos entrenados específicamente con patrones históricos locales de incendios para estimar riesgo a escala municipal. **Piriscopes** cruza datos meteorológicos oficiales (AEMET) con el histórico georreferenciado de incendios (EFFIS) para estimar, día a día y municipio a municipio, el nivel de riesgo relativo de incendio forestal en una región piloto (Galicia). Va dirigido a técnicos de protección civil y gestión forestal autonómica, y aporta un mapa de riesgo explicable que mejora la priorización de vigilancia frente a los índices estáticos actuales.

El tema y el problema

- **Qué pasa hoy:** la asignación de recursos de vigilancia y prevención se apoya en índices meteorológicos genéricos (FWI, Fire Weather Index) que no incorporan el patrón histórico real de incendios de cada zona.
- **Qué duele:** España registra de media más de 6.000 incendios forestales al año y cerca de 54.000 hectáreas quemadas en la última década (datos del MITECO), con un coste humano, ecológico y económico muy alto; una priorización más precisa de qué zonas vigilar puede reducir tiempos de respuesta.
- **Por qué es importante:** es un problema con datos públicos de calidad ya disponibles y con potencial aplicación en administraciones públicas, empresas aseguradoras y gestores agroforestales.

Objetivo principal del proyecto

Piriscopes: Construcción de un sistema predictivo basado en aprendizaje supervisado que permita estimar diariamente el riesgo de incendio forestal por municipio en Galicia para mejorar la priorización de recursos de vigilancia y prevención. El éxito mínimo del proyecto consistirá en generar una predicción diaria de riesgo para al menos el 80% de los municipios gallegos utilizando fuentes públicas de datos.

Alcance inicial (IN / OUT)

IN:

- Región piloto: Galicia (alto histórico de incendios y buena cobertura de datos).
- Ingesta de meteorología diaria (AEMET) e histórico de incendios georreferenciado (EFFIS, complementado con EGIF-MITECO donde esté disponible).
- Pipeline de cruce espacio-temporal y generación de features (racha de días secos, humedad acumulada, etc.).
- Modelo supervisado (XGBoost/Random Forest) comparado contra el baseline FWI que ya publica EFFIS a diario para toda Europa.
- Explicabilidad del modelo (SHAP) y demo/dashboard simple (Streamlit) con el mapa de riesgo.

OUT:


- Detección de incendios activos en tiempo real vía satélite/imagen.
- Componente espacial avanzado (CNN sobre raster de vegetación/NDVI) — se deja como ampliación opcional si el tiempo lo permite.
- Persistencia en base de datos (SQLite o PostgreSQL+PostGIS) para servir consultas en vivo o guardar histórico de predicciones — no es necesaria para el núcleo (se trabaja con ficheros Parquet/CSV), se deja como posible ampliación futura.
- Cobertura de toda España; predicción de propagación una vez iniciado el fuego; integración con sistemas reales de protección civil.

Usuarios / partes interesadas

- **Usa:** técnicos de protección civil y servicios de prevención forestal autonómicos.
- **Decide:** administración autonómica de medio ambiente.
- **Se beneficia:** población de zonas rurales en riesgo, gestores forestales, empresas aseguradoras del sector agroforestal.
- **Podría estar afectado:** comunidades cuya zona se clasifique como de alto riesgo (riesgo de estigmatización si el modelo se usa sin contexto humano); se documentará como limitación ética del sistema.

Propuesta de solución (alto nivel)

- **Ingesta:** descarga periódica vía API de AEMET (meteorología) y descarga de EFFIS/EGIF (histórico de incendios).
- **Procesamiento (Big Data):** pipeline de features implementado inicialmente con herramientas locales (pandas), escalable a procesamiento distribuido (Spark/Dask) si el volumen de datos lo requiere.
- **Modelado:** clasificador supervisado (XGBoost/Random Forest) entrenado sobre una variable objetivo binaria (hubo/no hubo incendio en un radio y ventana temporal definidos), construida desde el histórico de EFFIS, usando como variables predictoras las condiciones meteorológicas diarias (temperatura, humedad relativa, viento, precipitación acumulada, racha de días secos). El nivel de riesgo relativo que se muestra en el mapa final es la probabilidad estimada por el clasificador, categorizada en bajo/medio/alto si el balance de clases lo permite, y se compara contra el baseline FWI que ya publica diariamente EFFIS.
- **Explicabilidad:** SHAP para identificar qué variables elevan el riesgo en cada caso.
- **Presentación:** dashboard/demo (Streamlit) con mapa de riesgo por municipio y día.



Datos (estimación inicial)

- **Volumen:** Aproximadamente $300 \text{ municipios} \times 365 \text{ días} \times 15 \text{ años} \approx 1,6 \text{ millones de observaciones}$.
- **Fuentes candidatas:** AEMET OpenData (meteorología, pública/oficial); EFFIS — JRC/Comisión Europea (histórico de incendios georreferenciado, licencia CC-BY 4.0); EGIF-MITECO como complemento puntual. EFFIS además calcula y publica a diario el índice FWI para toda Europa, aprovechable directamente como baseline sin necesidad de recalcularlo desde cero.
- **Tipo:** públicos y oficiales; series temporales tabulares (meteorología) y datos geoespaciales vectoriales (perímetros de incendio).
- **Riesgos de acceso/licencias:** EGIF-MITECO tiene datos definitivos solo hasta 2016 y está fragmentado por provincia en años posteriores; se mitiga usando EFFIS como fuente principal. El dataset consolidado y descargable de EFFIS/JRC solo cubre de forma limpia el periodo 2000-2017, por lo que los años más recientes pueden requerir el visor EFFIS (Current Situation Viewer) en vez de descarga masiva. Sin datos personales ni PII en ningún caso.

Viabilidad técnica (análisis mínimo)

- **Fácil:** obtención de datos meteorológicos vía API bien documentada; modelado tabular con librerías estándar (XGBoost, scikit-learn); el baseline FWI no hay que construirlo, ya lo publica EFFIS a diario.
- **Difícil:** unir espacialmente el histórico de incendios (geolocalizado) con unidades administrativas (municipio); construir un conjunto de «no incendio» representativo, ya que el histórico solo registra eventos positivos.
- **Tecnología prevista:** Python (pandas/Spark), XGBoost/scikit-learn, SHAP, Streamlit, Git/GitHub.
- **Incertidumbres:** granularidad y continuidad real de EFFIS para España; disponibilidad de series meteorológicas completas por municipio (puede requerir interpolación entre estaciones).

Riesgos principales y plan B:

Riesgo	Plan B
Histórico de incendios fragmentado/incompleto en la fuente española (EGIF, provisional tras 2016)	Usar EFFIS (JRC/Comisión Europea) como fuente principal de eventos, geolocalizada y con licencia abierta; EGIF solo como complemento puntual
El dataset consolidado y descargable de EFFIS/JRC solo cubre de forma limpia el periodo 2000-2017	Completar años recientes con los avisos/CSV del visor EFFIS (Current Situation Viewer) o acotar el periodo de entrenamiento a 2000-2017 si la calidad posterior no es suficiente
Exceso de alcance (cubrir toda España o el componente geoespacial avanzado desde el inicio)	Acotar a una única comunidad autónoma piloto (Galicia); tratar el modelo espacial (CNN sobre NDVI/terreno) como ampliación opcional, no como núcleo
Fuerte desbalanceo de clases (incendio vs. no incendio) impide alcanzar métricas razonables	Aplicar SMOTE / pesos de clase; evaluar con recall y AUC-PR en vez de accuracy
Pipeline de Big Data demasiado complejo para el tiempo disponible	El desarrollo inicial se realizará con pandas para validar hipótesis y reducir complejidad. La adopción de Spark se valorará únicamente si el tamaño de los datos o los tiempos de procesamiento lo justifican
Riesgo de estigmatización de municipios clasificados como de alto riesgo	Comunicar el resultado como apoyo probabilístico para priorizar recursos, no como veredicto determinista; evitar publicar rankings públicos sin contexto
El modelo no supera significativamente al FWI	Convertir el proyecto en un sistema explicativo y comparativo respecto al FWI, centrándose en interpretabilidad y análisis regional

Reparto de tareas

- **Data:** Cristina / Hikari
- **ML:** Hikari / Cristina
- **BI:** Cristina / Hikari
- **Dev:** Hikari / Cristina
- **Platform:** Compartido
- **Management:** Cristina / Hikari

Principal / Apoyo

Próximos pasos inmediatos (7 días)

- Estructurar repositorio Git.
- Descargar muestra de AEMET y EFFIS.
- Validar estructura de datos.
- Revisar propuesta de variable objetivo: Predicción municipio + día + incendio (SI|NO).
- Realizar primer análisis exploratorio.
- Confirmar arquitectura inicial.

Acuerdo de trabajo (resumen)

- **Canal principal de comunicación:** Discord, WhatsApp.
- **Disponibilidad:** Cristina (10 horas/semana), Hikari (12-16 horas/semana).
- **Frecuencia de reuniones:** 1-2 por semana, 30-60 minutos, a demanda en fases pico del proyecto.

Reglas básicas: no se sube nada a main sin PR · toda tarea tiene una issue asignada · las decisiones se documentan en el repositorio · se respeta el reparto pero se ayuda si hay bloqueo.