2026

DOCUMENTACIÓN Y DISEÑO TÉCNICO “PIRISCOPE”

PIRISCOPE

“SISTEMA DE ESTIMACIÓN DIARIA DE RIEGSO DE INCENDIO FORESTAL POR MUNICIPIO”

(CO88. PROYECTO DE INTELIGENCIA ARTIFICIAL Y BIG DATA)

AUTORES:

HIKARI LHEKU BARRIO MARTÍN

CRISTINA PUÉRTOLAS REBOLLAR

GUILLERMO RAMÓN SERRANO

ALEJANDRO ESCOLAR ESPEJO

Contents

1. Título del proyecto e integrantes del equipo 2
2. Resumen ejecutivo 2
3. Descripción funcional del sistema 2
4. Alcance definitivo (IN/OUT) 4
Incluye 4
No incluye 4
5. Arquitectura del sistema (alto nivel) 5
6. Tecnologías seleccionadas 9
8. Datos 14
9. Ética, legalidad y accesibilidad 17
10. Backlog inicial 18
11. Plan de trabajo 18
12. Estrategia de desarrollo 19
13. Riesgos técnicos actualizados 21
14. Repositorio del proyecto 23
Anexo A. Diccionario de variables 25
Anexo B. Fuentes y enlaces 29

Nota de transparencia: *en la elaboración de este documento se ha utilizado asistencia de herramientas de inteligencia artificial generativa para tareas de revisión, estructuración y redacción técnica. El contenido ha sido revisado y validado por el equipo, que asume su autoría.*

1. Título del proyecto e integrantes del equipo

Nombre del proyecto: Piriscope, sistema de estimación diaria de riesgo de incendio forestal por municipio (Grupo 6, módulo C088).

Integrantes y rol principal

- **Cristina Puértolas Rebollar:** fuentes de datos, data ingest y coordinación general del proyecto (Management).
- **Hikari Lheku Barrio Martín:** Machine Learning y explicabilidad (ML).
- **Guillermo Ramón Serrano:** limpieza, normalización, tipado y cruce espacio-temporal de los datos (Data Engineering).
- **Alejandro Escolar Espejo:** Presentación de resultados mediante dashboard Streamlit (Frontend Dev).

El reparto de roles define la responsabilidad principal de cada integrante, aunque se contempla apoyo cruzado entre los miembros del equipo cuando sea necesario.

2. Resumen ejecutivo

Los índices de riesgo de incendio forestal en uso, como el FWI, se basan casi exclusivamente en variables meteorológicas y no incorporan el patrón histórico real de incendios de cada zona, lo que limita la precisión con la que se priorizan los recursos de vigilancia y prevención.

Piriscope es un sistema de predicción del riesgo relativo de incendio forestal para una región piloto de Galicia. Combina datos meteorológicos de AEMET con el histórico de incendios de EGIF-MITECO para entrenar un modelo supervisado (XGBoost y/o Random Forest) que estima, para cada municipio, la probabilidad de incendio del día siguiente. El resultado se compara con el FWI de EFFIS/Copernicus como baseline, se explica con SHAP y se presenta en un dashboard Streamlit.

El valor está en convertir un índice genérico en una estimación local, explicable y basada en datos históricos reales. El éxito mínimo es un pipeline reproducible que genere predicciones diarias para al menos el 80 % de los municipios gallegos con fuentes exclusivamente públicas, y demostrar con métricas objetivas (Recall y AUC-PR) su comportamiento frente al baseline.

3. Descripción funcional del sistema

Qué hace exactamente la aplicación

Piriscope integra datos meteorológicos, datos históricos de incendios y el índice FWI para generar una estimación diaria del riesgo relativo de incendio forestal en los municipios de la región piloto.

El sistema estará compuesto por las siguientes etapas:

1. Ingesta y preparación de datos meteorológicos procedentes de AEMET.
2. Ingesta y transformación del histórico de incendios procedente principalmente de EGIF-MITECO.
3. Obtención e integración del FWI procedente de EFFIS/Copernicus.
4. Cruce espacial y temporal de las diferentes fuentes.
5. Generación de variables derivadas.
6. Entrenamiento y validación de los modelos supervisados.
7. Comparación frente al baseline FWI.
8. Generación de explicaciones mediante SHAP.
9. Presentación de resultados mediante un dashboard.

Flujo general de uso

1. Se incorporan las últimas observaciones meteorológicas de AEMET y el FWI del día, asociando cada municipio a su estación más cercana.
2. El pipeline procesa y transforma las fuentes de datos.
3. El modelo entrenado genera una probabilidad estimada de incendio para cada municipio para el día siguiente (D+1), a partir de la información disponible hasta el día D.
4. El sistema categoriza dicha probabilidad en tres niveles de riesgo (bajo, medio y alto).
5. La persona usuaria consulta el dashboard.
6. El dashboard muestra el riesgo estimado, el valor del FWI utilizado como referencia y las variables que más han influido en la predicción.

Público objetivo

- Técnico de protección civil que consulta el riesgo estimado de una zona.
- Gestor forestal que compara el riesgo entre distintos municipios.
- Miembro del equipo que analiza el comportamiento del modelo.
- Miembro del equipo que incorpora nuevos datos y re entrena el modelo.

Definición de riesgo y horizonte de predicción

El riesgo se define como la probabilidad de que un municipio registre al menos un parte de incendio en EGIF el día D+1. El modelo utiliza la información disponible hasta el día D (meteorología observada, FWI y variables derivadas) y no emplea previsión meteorológica a varios días vista. Los umbrales que separan los niveles bajo, medio y alto se fijarán sobre el conjunto de validación tras el análisis exploratorio (EDA).

Qué puede y qué no puede hacer el sistema

El sistema puede:

- Estimar el riesgo relativo diario de incendio forestal por municipio.
- Comparar la predicción del modelo con el baseline FWI.
- Mostrar las variables que más influyen en una predicción mediante SHAP.
- Visualizar espacialmente el riesgo estimado.

El sistema no puede:

- Detectar incendios ya activos en tiempo real.
- Predecir la propagación de un incendio una vez iniciado.
- Sustituir a los sistemas oficiales de protección civil.
- Garantizar que un incendio vaya a producirse.
- Cubrir inicialmente todo el territorio español.
- Utilizar previsión meteorológica a varios días vista.

La primera versión se limitará a Galicia como región piloto.

4. Alcance definitivo (IN/OUT)

Incluye

Funcionalidades mínimas obligatorias:

- Ingesta y procesamiento de datos meteorológicos diarios procedentes de AEMET.
- Ingesta y procesamiento del histórico de incendios forestales procedente de EGIF-MITECO.
- Integración del FWI procedente de EFFIS/Copernicus como variable y como baseline de comparación.
- Cruce espacio-temporal de los datos a nivel municipal.
- Generación de variables derivadas relevantes para el riesgo de incendio.
- Entrenamiento de modelos supervisados XGBoost y/o Random Forest.
- Comparación del modelo supervisado frente al baseline FWI.
- Evaluación mediante métricas adecuadas para clasificación desbalanceada, incluyendo al menos Recall y AUC-PR.
- Explicabilidad mediante SHAP.
- Dashboard desarrollado con Streamlit.
- Visualización del riesgo estimado por municipio.
- Consulta de la predicción y de las variables que más han contribuido a ella.

Funcionalidades opcionales:

- Incorporación de variables espaciales adicionales, como vegetación, NDVI o características del terreno.
- Persistencia en base de datos mediante SQLite o PostgreSQL + PostGIS.
- Procesamiento distribuido mediante PySpark si el volumen de datos final lo justifica.
- Incorporación de nuevas fuentes de datos ambientales.
- Automatización completa de la actualización de predicciones.

No incluye

- Detección de incendios activos mediante imágenes de satélite.
- Predicción de propagación de incendios.
- Simulación física del comportamiento del fuego.
- Cobertura inicial de todo el territorio español.
- Integración con sistemas reales de protección civil.
- Sustitución de los sistemas oficiales de predicción o gestión de emergencias.
- Uso de EFFIS como fuente de eventos individuales de incendio (su acceso público no ofrece el histórico individual necesario).
- Utilización de previsión meteorológica a varios días vista como entrada del modelo.

5. Arquitectura del sistema (alto nivel)

La arquitectura del sistema se organiza en un pipeline de datos basado en una arquitectura medallón, con las capas Bronze, Silver y Gold, sobre las que se construyen los componentes de Machine Learning y presentación mediante Streamlit.

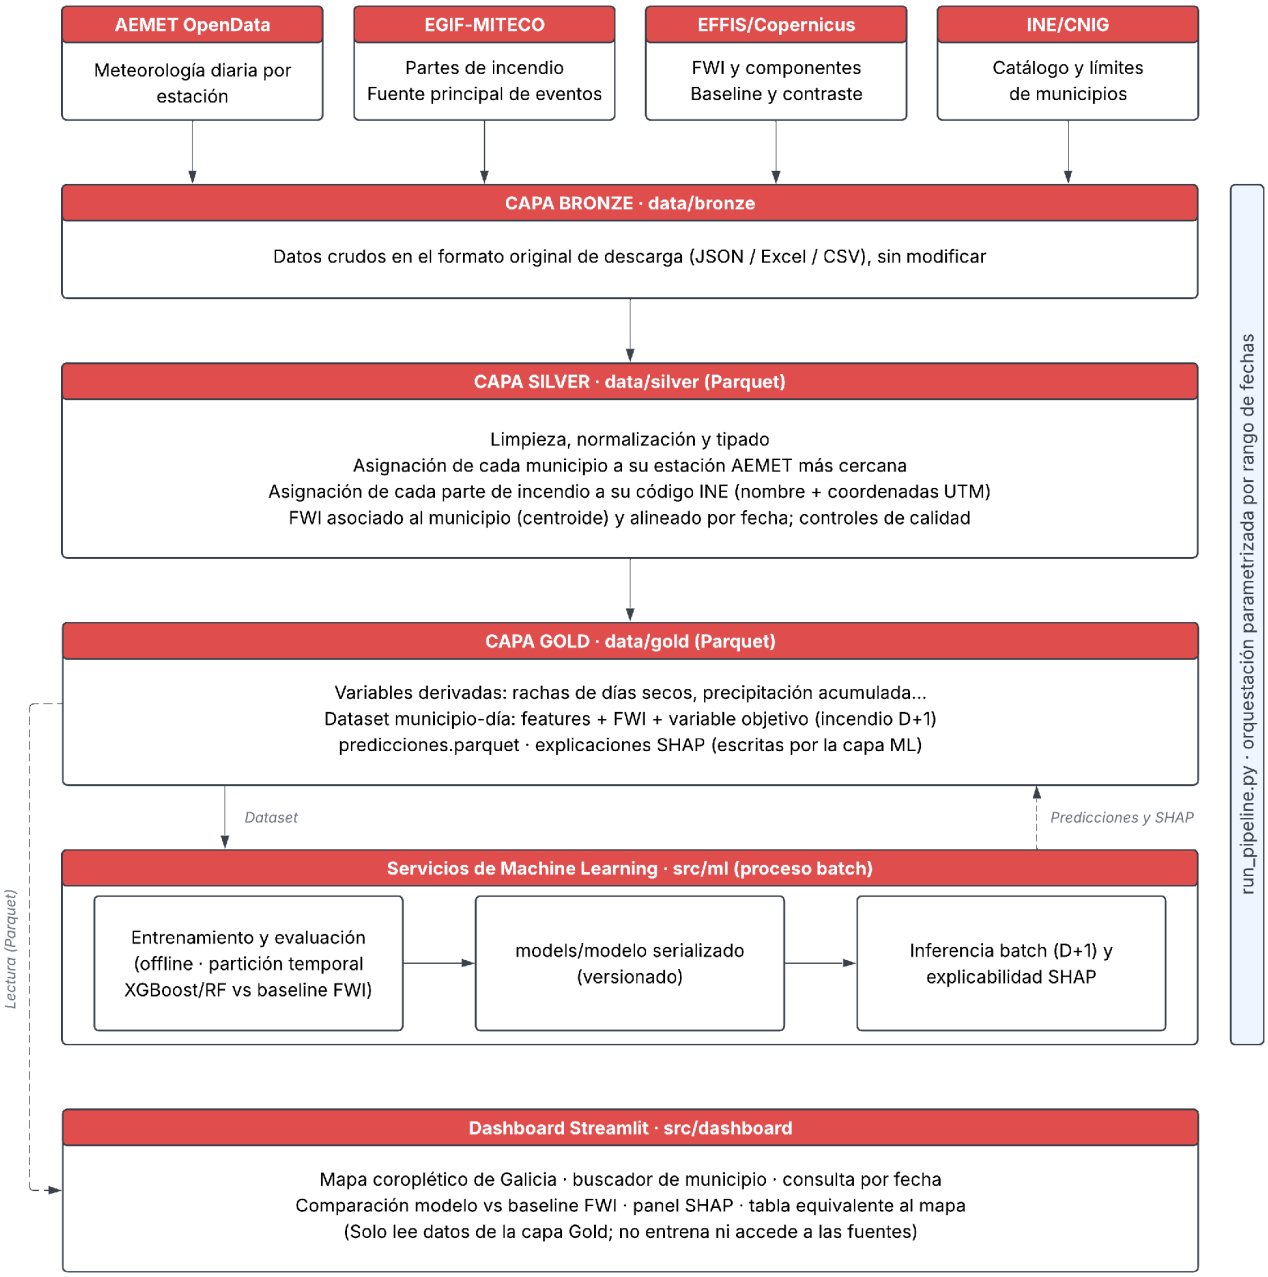


Figura 1. Arquitectura lógica de Piriscope: pipeline medallón (Bronze, Silver, Gold), servicios de ML en proceso batch y dashboard Streamlit que solo lee la capa Gold.

5.1. Fuente de datos

- **AEMET:** datos meteorológicos diarios por estación (requiere API key).
- **EGIF-MITECO:** histórico de incendios forestales, utilizado como fuente principal de eventos reales.
- **EFFIS/Copernicus:** FWI y otros datos relacionados con el peligro meteorológico de incendios.
- **INE / CNIG:** catálogo y límites de los municipios (códigos INE y centroides).

5.2. Pipeline de datos

El pipeline seguirá una arquitectura medallón, organizada en tres capas de calidad creciente: Bronze, Silver y Gold, implementadas mediante directorios de ficheros en data/bronze, data/silver y data/gold, sin necesidad de utilizar un motor de base de datos.

El pipeline realizará las siguientes etapas:

- Descarga o incorporación de los datos desde las fuentes seleccionadas almacenandose en HugginFace datasets.
- Para la ingesta automática, se creará un token fine-grained con permiso de escritura solo sobre el dataset. Se guardará como HF_TOKEN en los Secrets del repositorio de GitHub.
- Limpieza, normalización y tipado de los datos.
- Homogeneización temporal de las diferentes fuentes.
- Asociación espacial de los incendios a los municipios mediante su código INE (por nombre de municipio, validado con las coordenadas UTM de EGIF).
- Integración de la información meteorológica de AEMET, asociando cada municipio a su estación más cercana y registrando la distancia como indicador de calidad.
- Incorporación del FWI y sus componentes, asociados al municipio por su centroide, como referencia y variables complementarias.
- Generación de variables derivadas para el modelo.
- Construcción del dataset final de entrenamiento y predicción.

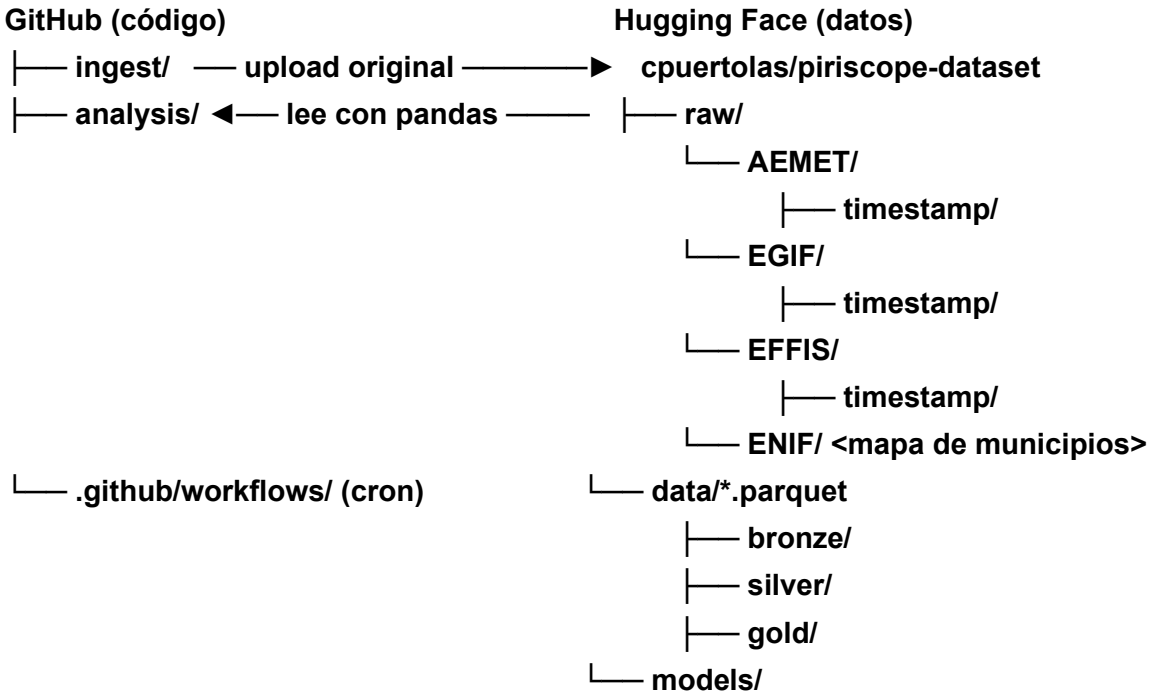
El proyecto organiza los datos en tres capas.

Bronze guarda los datos crudos tal como se descargan: la meteorología diaria de AEMET y el histórico de incendios de EGIF-MITECO (fuente principal de eventos), mientras que EFFIS/Copernicus se usa solo para el FWI y la validación. Cada descarga se archiva por fecha de ingesta y fuente, sin modificar el original, para garantizar la trazabilidad.

Silver aplica limpieza, normalización y tipado, y convierte los datos a Parquet. Aquí se cruzan las fuentes en espacio y tiempo: los incendios se asignan a municipios mediante el código INE (con tabla de equivalencias para municipios modificados), y el FWI se asocia a cada municipio por su centroide y se alinea por fecha. Se aplican controles de calidad (duplicados, cobertura, valores fuera de rango) y se añaden columnas de trazabilidad (fecha de procesamiento).

Gold genera las variables derivadas (como la racha de días secos y otros acumulados) y consolida en Parquet el dataset final para el entrenamiento del modelo y el dashboard. También almacena las predicciones diarias y las explicaciones SHAP. Conserva la trazabilidad heredada de Silver, añade la suya propia e incluye la versión del modelo que generó cada predicción.

5.3. Diagrama de ingesta automática



5.4. Servicios de machine learning

El sistema contará con:

- Módulo de entrenamiento.
- Módulo de validación y evaluación (partición temporal y geográfica).
- Módulo de inferencia: calcula en modo batch las predicciones del día siguiente y las escribe en la capa Gold.
- Módulo de explicabilidad mediante SHAP: calcula las explicaciones en el mismo proceso batch.

Estos módulos parten del dataset ya construido en la capa Gold por el pipeline de datos (src/features).

El entrenamiento se realizará de forma offline. El modelo resultante se serializará en models/ (versionado) y solo lo utilizará el módulo de inferencia.

5.5. Almacenamiento

El núcleo del proyecto utilizará ficheros Parquet y CSV organizados en las carpetas de datos del repositorio “HuggingFace dataset”: https://huggingface.co/datasets/cpuertolas/piriscope

No se considera necesaria una base de datos para la primera versión debido al volumen previsto y a la naturaleza del prototipo. SQLite o PostgreSQL + PostGIS quedan como ampliaciones posibles.

5.6. Frontend y Backend

Se utilizará una **arquitectura monolítica basada en Streamlit**, manteniendo frontend y backend dentro de un único componente.

Al tratarse de un procesamiento principalmente batch, las predicciones y las explicaciones SHAP se calculan previamente a partir de los datos de la capa Gold, por lo que no es necesario un servicio independiente que responda a consultas en tiempo real. Streamlit se encarga de la interfaz visual, de la lectura de la capa Gold y de la presentación de las predicciones ya generadas; no carga ni ejecuta el modelo.

Esta decisión de arquitectura responde al tamaño del equipo de proyecto y al objetivo de desarrollar un **MVP funcional**, evitando introducir la complejidad adicional de separar frontend y backend sin que resulte necesaria para el alcance del proyecto.

Separación lógica de capas y comunicación entre módulos: aunque el despliegue es monolítico, la lógica no reside en la interfaz. El código de src/ se organiza en módulos (ingest, features, ml, explainability, dashboard) que se comunican únicamente mediante ficheros Parquet en data/ y el modelo serializado en models/. El dashboard nunca entrena ni accede a las fuentes externas.

5.7. Dashboard

El dashboard incluirá:

- Mapa de Galicia con el riesgo estimado por municipio.
- Selección o búsqueda de municipios.
- Consulta de la predicción para una fecha.
- Valor del FWI utilizado como referencia.
- Comparación entre modelo y baseline.
- Visualización de explicaciones SHAP.
- Alternativa tabular al mapa (tabla ordenable de municipios con su nivel de riesgo).

5.8. Otros servicios

Un único punto de orquestación (run_pipeline.py), parametrizable por rango de fechas, encadena ingesta → Silver → Gold → entrenamiento/inferencia. No se prevén colas de mensajería, autenticación ni servicios externos más allá de las descargas de datos.

6. Tecnologías seleccionadas

Categoría	Tecnología	Por qué se ha elegido	Alternativa descartada
Lenguaje	Python	Amplio ecosistema para análisis de datos, Machine Learning y visualización.	R , descartado por menor integración con el ecosistema utilizado por el equipo.
Procesamiento de datos	pandas	Adecuado para el volumen inicialmente estimado y sencillo de integrar con el resto del proyecto.	PySpark descartado por requerir una infraestructura de procesamiento distribuido (por ejemplo, Hadoop) que supone un esfuerzo de despliegue y mantenimiento no justificado para el volumen de datos manejado.
Modelado	XGBoost / Random Forest	Modelos adecuados para datos tabulares, capaces de trabajar con relaciones no lineales y compatibles con técnicas de explicabilidad.	Red neuronal densa, por no existir inicialmente un volumen de datos que justifique su complejidad.
Explicabilidad	SHAP	Permite analizar la contribución de las variables en modelos basados en árboles.	LIME, al priorizar SHAP para mantener una metodología de explicación homogénea con los modelos seleccionados.
Visualización	Streamlit	Permite desarrollar un dashboard funcional rápidamente a partir de las predicciones precalculadas.	Flask + React, por introducir complejidad adicional innecesaria para el MVP.
Control de versiones	Git / GitHub	Estándar de la industria; permite trabajar con ramas, Pull Requests e issues.	GitLab, descartado por normas del proyecto.
Almacenamiento	Ficheros Parquet / CSV /HuggingFace datasets	Adecuado para el volumen previsto y facilita el procesamiento con Python.	PostgreSQL + PostGIS, que queda como ampliación opcional.
Geoespacial y mapas	GeoPandas + Plotly	Permite asociar estaciones y partes de incendio a los municipios y dibujar el mapa coroplético dentro de Streamlit sin servidor de mapas.	Folium / PostGIS, por mayor complejidad para el MVP.
Pruebas e integración	pytest + GitHub Actions	Pruebas unitarias sobre el cruce de datos y las features, ejecutadas automáticamente en cada Pull Request.	Solo pruebas manuales, por menor trazabilidad.

7. Modelo de datos

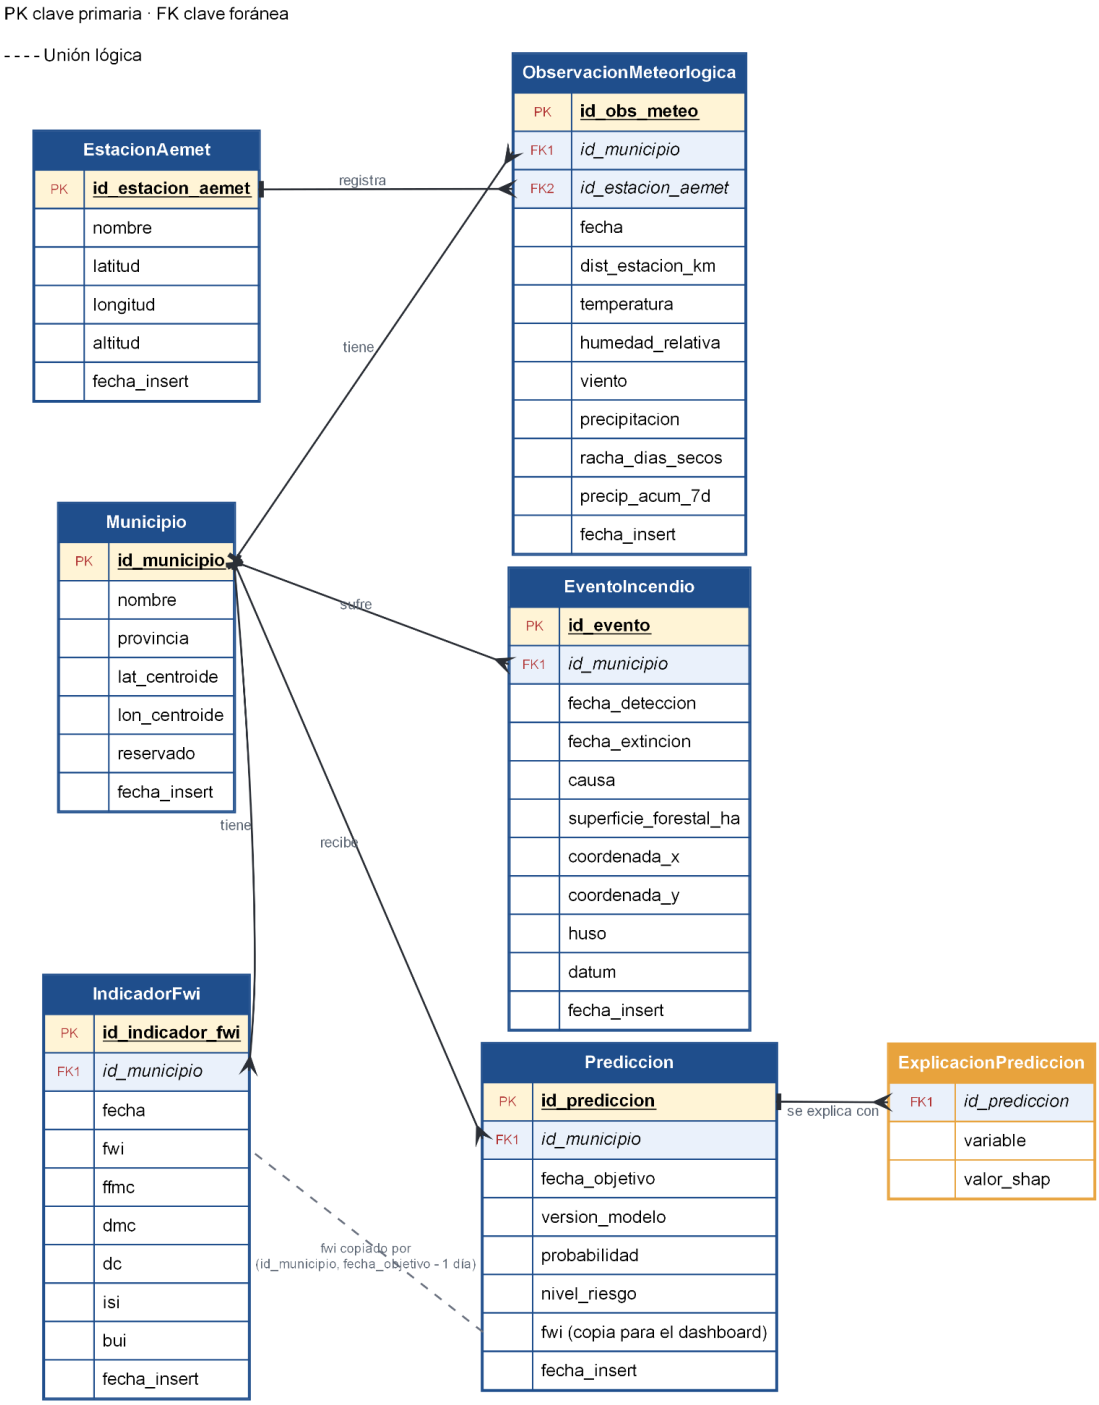


Figura 2. Modelo de datos de Piriscope (esquema entidad-relación). Los datos se materializan como ficheros Parquet; claves y relaciones se mantienen a nivel lógico.

El modelo de datos se materializará principalmente mediante ficheros Parquet. Las entidades descritas a continuación representan conceptualmente la información utilizada por el pipeline: las cinco primeras (Municipio, EstacionAemet, ObservacionMeteorologica, EventoIncendio e IndicadorFWI) corresponden a Silver, y las dos últimas (Prediccion y ExplicacionPrediccion) son salida de Gold. Las variables derivadas, como racha_dias_secos y precip_acum_7d, se calculan en Gold y se consolidan en la tabla de entrenamiento descrita más abajo.

Municipio

Catálogo de los municipios de Galicia (región piloto) identificados por su código INE.

Campos:

- **id_municipio *** (PK): código INE del municipio
- nombre, provincia
- lat_centroide
- lon_centroide (el centroide se usa para asociar la estación y el FWI y para dibujar el mapa) y reservado (indica si el municipio está reservado para la evaluación geográfica; se carga desde docs/municipios_reservados.csv)
- reservado
- fecha_insert: marca de tiempo del registro

Relaciones: 1—N con ObservacionMeteorologica, EventoIncendio, IndicadorFWI y Prediccion.

EstacionAemet

Estaciones meteorológicas de AEMET con datos diarios.

Campos:

- **id_estacion_aemet** * (PK)
- nombre
- latitud
- longitud
- altitud
- fecha_insert: marca de tiempo del registro.

Relación: 1—N con ObservacionMeteorologica (cada municipio se asocia a su estación más cercana).

ObservacionMeteorologica

Variables meteorológicas de la estación asignada a un municipio en una fecha.

Campos:

- **id_obs_meteo** (PK): id_municipio + fecha
- id_municipio (FK)
- id_estacion_aemet (FK)
- dist_estacion_km (indicador de calidad)
- temperatura
- humedad_relativa
- viento
- precipitacion
- racha_dias_secos
- precip_acum_7d.
- fecha_insert: marca de tiempo del registro.

La granularidad objetivo será: municipio + día.

EventoIncendio

Partes de incendio forestal registrados históricamente en EGIF-MITECO y asociados a un municipio por su nombre, validado con las coordenadas UTM.

Campos:

- **id_evento** (PK): formada por campaña y número de parte
- id_municipio (FK)
- fecha_deteccion
- fecha_extincion
- causa
- superficie_forestal_ha
- coordenada_x
- coordenada_y
- huso
- datum
- fecha_insert: marca de tiempo del registro

EFFIS solo podrá utilizarse como fuente independiente para contrastar la información, no como fuente de eventos.

IndicadorFWI

Valor del Fire Weather Index y de sus componentes (FFMC, DMC, DC, ISI y BUI) para un municipio y día, muestreados en su centroide desde EFFIS/Copernicus.

Campos:

- **id_indicador_fwi** (PK): id_municipio + fecha
- id_municipio (FK)
- fecha
- fwi
- ffmc
- dmc
- dc
- isi
- bui
- fecha_insert: marca de tiempo del registro

Se utiliza como variable del modelo y como baseline de comparación.

Prediccion

Salida del modelo para un municipio y un día objetivo.

Campos:

- **id_prediccion** (PK): id_municipio + fecha_objetivo
- id_municipio (FK)
- fecha_objetivo
- Probabilidad estimada
- Nivel de riesgo
- Valor del FWI del mismo día: copiado de IndicadorFWI para el dashboard, es el día anterior a la fecha objetivo
- Versión del modelo utilizado

- fecha_insert: marca de tiempo del registro

ExplicacionPrediccion

Explicación SHAP de las variables de una predicción.

Campos:

- id_prediccion (FK)
- variable
- valor_shap

Prediccion 1 ─ N ExplicacionPrediccion.

Relaciones y claves

Municipio (1—N) ObservacionMeteorologica, EventoIncendio, IndicadorFWI y Prediccion; EstacionAemet (1—N) ObservacionMeteorologica; Prediccion (1—N) ExplicacionPrediccion. Las relaciones se establecen mediante las claves foráneas `id_municipio` (presente en ObservacionMeteorologica, EventoIncendio, IndicadorFWI y Prediccion), `id_estacion_aemet` (en ObservacionMeteorologica) e `id_prediccion` (en ExplicacionPrediccion).

Todas las entidades tienen una clave primaria. `Municipio`, `EstacionAemet`, `ObservacionMeteorologica`, `IndicadorFWI`, `Prediccion` y `EventoIncendio` utilizan respectivamente `id_municipio`, `id_estacion_aemet`, `id_obs_meteo`, `id_indicador_fwi`, `id_prediccion` e `id_evento` como identificadores. `ExplicacionPrediccion` utiliza una clave primaria compuesta por `id_prediccion` y `variable`, siendo `id_prediccion` simultáneamente clave foránea hacia Prediccion. Los identificadores de observación, FWI y predicción son derivados de sus claves naturales: `id_municipio + fecha` en observaciones y FWI, y `id_municipio + fecha_objetivo + version_modelo` en predicciones. `id_parte`, el identificador original de EGIF, se conserva como valor único en EventoIncendio.

La unicidad de las filas se garantiza en el pipeline mediante tests de duplicados y controles de calidad, y no mediante restricciones de una base de datos.

El campo `fwi` de Prediccion se obtiene lógicamente a partir de `IndicadorFWI`: para un mismo `id_municipio`, se utiliza el valor de FWI correspondiente al día anterior a `fecha_objetivo`, es decir, cuando `IndicadorFWI.fecha = Prediccion.fecha_objetivo − 1 día`.

La tabla de entrenamiento es una vista desnormalizada que integra ObservacionMeteorologica e IndicadorFWI, añade los campos necesarios de Municipio, la columna de partición y la variable objetivo derivada de EventoIncendio.

Las explicaciones SHAP se representan mediante la entidad débil ExplicacionPrediccion, que almacena para cada predicción la variable utilizada y su correspondiente `valor_shap`.

Variable	Tipo	Descripción
id_municipio	texto	Identificador INE del municipio (clave). No se utiliza como variable del modelo.
particion	categórico	Partición temporal de la fila según su fecha: entrenamiento, validación o test (el test es el último año completo). Se fija al inicio del proyecto y no se modifica.
reservado	binario	1 si el municipio está reservado para la evaluación geográfica y nunca se usa en el entrenamiento; 0 en caso contrario.
fecha	fecha	Día D de la observación (clave junto a id_municipio).
precipitacion	numérico	Precipitación acumulada diaria (mm).
racha_dias_secos	numérico	Días consecutivos sin precipitación relevante (variable derivada).
fwi	numérico	(Fire Weather Index): variable y baseline; el modelo se evaluará también sin FWI ni sus componentes para que la comparación no sea circular.
incendio_d1 (objetivo)	binario	1 si el municipio registra al menos un parte de incendio (EGIF) con fecha de detección D+1; 0 en caso contrario.

El diccionario de variables completo se incluye en el **Anexo A**.

Trazabilidad

Todas las entidades materializadas en las capas Silver y Gold incluyen, además de los campos descritos en cada una, una columna técnica común: fecha_insert, con la marca de tiempo en la que se generó esa fila. Si se detecta un valor anómalo, permite identificar cuándo se generó. Cada ejecución sobrescribe los datos del periodo reprocesado, por lo que no se conservan versiones anteriores ni duplicados.

8. Datos

Fuentes de datos geoespaciales

El proyecto utiliza cuatro fuentes públicas. Los enlaces de acceso se recogen en el **Anexo B**.

AEMET OpenData

Fuente principal de información meteorológica diaria por estación.

Variables de interés:

- Temperatura.
- Precipitación.
- Humedad.

- Viento.
- Otras variables meteorológicas disponibles que puedan resultar relevantes para el modelo.

AEMET OpenData exige una API key, aunque las claves generadas desde el 13 de septiembre de 2017 tienen validez indefinida. Se configurará en el codespace dedicado.

EGIF-MITECO (Estadística General de Incendios Forestales)

Fuente principal del histórico de incendios forestales.

Los datos contienen información de los incendios registrados en España, incluyendo fecha de detección y extinción, causa, superficie, municipio y coordenadas UTM.

Los datos disponibles deberán procesarse y homogeneizarse para construir un histórico utilizable por el modelo. En particular, se prestará atención a la fragmentación de determinados datos por provincia y periodo.

El histórico de incendios se transformará para poder obtener, para cada municipio y día, una variable objetivo que indique si se produjo al menos un incendio durante la ventana temporal definida.

EFFIS / Copernicus

EFFIS se utilizará principalmente para obtener información relacionada con el **Fire Weather Index (FWI)** y como referencia independiente para evaluar el modelo.

El FWI se utilizará como **baseline**, es decir, como sistema de referencia frente al que comparar el modelo supervisado.

EFFIS no será considerado la fuente principal de los registros individuales de incendios, ya que el acceso público disponible no proporciona el histórico individual completo que necesita el proyecto.

Licencias y reutilización

Todas las fuentes son de acceso libre y gratuito (AEMET OpenData requiere una API key gratuita y el Early Warning Data Store de Copernicus, registro gratuito).

Sus condiciones de reutilización son las siguientes y se citarán en el README del repositorio.

- **AEMET:** información del sector público reutilizable con fines comerciales y no comerciales según la nota legal de AEMET (Ley 37/2007, modificada por la Ley 18/2015), obtenida a través de AEMET OpenData. Requiere citar «Fuente: AEMET» o «Información elaborada utilizando, entre otras, la obtenida de la Agencia Estatal de Meteorología», y no sugerir que AEMET respalda el trabajo.
- **EGIF-MITECO:** datos oficiales de la Administración General del Estado, sujetos a la Ley 37/2007 y al RD 1495/2011. Requiere no desnaturalizar la información y citar «Origen de los datos: Ministerio para la Transición Ecológica y el Reto Demográfico». La distribución en datos.gob.es se publica bajo CC BY 4.0.
- **EFFIS/Copernicus:** datos del Servicio de Gestión de Emergencias de Copernicus (CEMS), gestionado por el Joint Research Centre, bajo licencia CC BY 4.0 (política de reutilización de la Comisión, Decisión 2011/833/UE), con atribución e indicación de cambios. Los índices FWI históricos (CEMS, DOI 10.24381/cds.0e89c522, producidos por el ECMWF) se distribuyen en el Early Warning Data Store también bajo CC BY 4.0.
- **INE:** reutilización según su aviso legal, citando «Fuente: Sitio web del INE: www.ine.es» o, con tratamiento, «Elaboración propia con datos extraídos del sitio web del INE: www.ine.es».
- **CNIG/IGN:** licencia compatible con CC BY 4.0 (Orden FOM/2807/2015), con mención obligatoria del origen y la propiedad de los datos (© Instituto Geográfico Nacional).

Tipo de datos

El proyecto combinará:

- Series temporales meteorológicas.
- Datos tabulares de incendios.
- Datos geoespaciales de localización de incendios.
- Datos espaciales asociados al FWI.
- Datos vectoriales de los límites municipales.

Volumen estimado

El volumen final dependerá del periodo histórico que pueda construirse de forma homogénea a partir de EGIF-MITECO, AEMET y los datos históricos de FWI.

Con 313 municipios × 365 días × 15 años se obtienen alrededor de 1,7 millones de observaciones municipio-día; si el periodo común de las fuentes se amplía a unos 25 años, el orden de magnitud pasa a unos 3 millones. Los días con incendio serán una fracción muy pequeña de ese total (la cifra exacta se determinará en el EDA), por lo que se espera un desbalanceo de clases marcado.

El periodo común disponible de AEMET, EGIF-MITECO y FWI, y por tanto el volumen definitivo, se establecerá después de completar la fase de adquisición y EDA.

Frecuencia de actualización

- **AEMET:** observaciones meteorológicas diarias, consultables mediante OpenData; el histórico se descarga una sola vez y la actualización diaria se incorpora con el pipeline.
- **EGIF-MITECO:** estadística oficial publicada por campañas anuales tras su consolidación (las campañas más recientes pueden ser provisionales); se trata como carga histórica estática para el entrenamiento y no como fuente en tiempo real.
- **EFFIS/Copernicus:** datos de FWI con actualización diaria e histórico disponible; el periodo común con AEMET y EGIF se comprobará al inicio del proyecto.

Calidad esperada

Se considera que las fuentes oficiales proporcionan datos de calidad suficiente para desarrollar el proyecto, aunque pueden existir:

- Datos meteorológicos faltantes.
- Diferencias de cobertura entre estaciones.
- Diferencias temporales entre las fuentes.
- Incidencias en la geolocalización de algunos incendios.
- Diferencias de cobertura entre años.
- Nombres de municipio inconsistentes en EGIF que dificultan la asignación al código INE.
- Posible subregistro de incendios pequeños en zonas remotas.

Estas cuestiones constituyen los principales riesgos de datos (faltantes, sesgos y ruido); se analizarán durante el EDA y se documentarán las decisiones de limpieza e imputación.

Construcción de la variable objetivo

La ausencia de un registro de incendio no constituye una observación negativa explícita.

Por ello, el dataset de entrenamiento se construirá mediante una unidad de análisis definida como **municipio + día**. Para cada unidad se determinará si existe al menos un incendio registrado en EGIF durante la ventana temporal establecida.

El proceso deberá tener en cuenta posibles problemas de cobertura y calidad del registro para evitar interpretar automáticamente una ausencia de datos como ausencia real de incendios.

Naturaleza de los datos

Todos los datos son reales, no simulados ni ficticios: observaciones oficiales de AEMET, partes de incendio registrados en la EGIF (MITECO) y el índice FWI calculado por el servicio Copernicus para EFFIS a partir del reanálisis meteorológico ERA5.

No se generan datos sintéticos. Los días sin incendio se construyen por ausencia de registro (ver arriba), lo que es una decisión de diseño y no un dato simulado.

Las fuentes y sus enlaces se incluyen en el Anexo A.

9. Ética, legalidad y accesibilidad

Datos personales (PII)

El proyecto no tiene como objetivo tratar datos personales. Las fuentes utilizadas contienen información meteorológica, territorial y de incendios forestales.

No se incorporarán datos personales al dataset final del proyecto.

Protección de datos y cumplimiento del RGPD (GDPR)

Dado que el sistema trabaja con datos ambientales y registros de incendios y no tiene como finalidad identificar personas, no se prevé tratar datos personales en el funcionamiento normal del sistema; por tanto, el RGPD no resulta de aplicación sustancial al proyecto. Los partes de EGIF recogen la causa y la motivación de cada incendio pero no identifican a personas; en el dataset solo se conservan los campos necesarios (minimización de datos) y la información se agrega a nivel de municipio y día.

No obstante, las condiciones de uso y licencias de cada fuente serán revisadas antes de la publicación o distribución del proyecto.

Riesgos de sesgo

Se contemplan los siguientes riesgos:

- Diferencias en la densidad de estaciones meteorológicas.
- Diferencias de cobertura y calidad de los registros históricos.
- Posibles diferencias de detección y registro entre periodos.
- Posibles diferencias geográficas en la calidad de los datos.
- Desbalance entre días con incendio y días sin incendio.
- Posible subregistro de incendios pequeños en zonas remotas, que puede clasificar como «sin incendio» días que sí lo tuvieron.

Medidas de mitigación

- Documentar los datos faltantes y el método de tratamiento utilizado.
- Evaluar las métricas de forma desagregada por provincia para detectar sesgos geográficos.
- Utilizar métricas adecuadas para clases desbalanceadas.
- Separar temporalmente entrenamiento y validación para evitar fuga de información.
- Documentar las limitaciones del dataset.
- Presentar las predicciones como estimaciones probabilísticas y no como certezas.

Accesibilidad

El dashboard tendrá en cuenta:

- Paletas de colores aptas para personas con daltonismo.
- Evitar depender exclusivamente del color para comunicar el nivel de riesgo.
- Etiquetas y textos descriptivos.
- Tamaño de fuente legible.
- Información numérica complementaria al mapa.

10. Backlog inicial

Backlog subido al Kanban del proyecto en github:
https://github.com/users/cristinapuertolas-80/projects/1/views/1

11. Plan de trabajo

Cronograma

Semana	Hito principal	Responsable	Dependencias
S1 (18/09–24/09) · **Entrega NF1** ✓	Presentación y viabilidad — entregada	Equipo	—
S2-S3 (25/09–08/10)	Adquisición y validación inicial de AEMET, EGIF-MITECO y EFFIS/Copernicus; comprobación del periodo común y del FWI municipal; definir y congelar la partición	Cristina (adquisición y validación)	Acceso a las fuentes confirmado
S4 (09/10–14/10) **Entrega NF2**	Documentación y diseño técnico; definición de arquitectura y modelo de datos (entrega el 14/10)	Equipo	Resultado del análisis inicial de las fuentes
S5-S6 (16/10–29/10)	Limpieza, normalización y cruce espacio-temporal de los datos. Punto de control: si el cruce no está validado, se recorta a funcionalidades mínimas	Cristina (cruce y calidad), Guillermo (pipeline)	Cruce de datos validado
S7 (30/10–05/11)	Generación de features y construcción del dataset de entrenamiento	Hikari, con apoyo de Cristina	Dataset inicial disponible
S8 (06/11–12/11) **Entrega NF3**	Entrenamiento inicial de XGBoost y/o Random Forest	Hikari	Dataset de entrenamiento completo
S9 (13/11–19/11)	Comparación frente al baseline FWI, evaluación y ajuste del modelo	Hikari (modelo), Cristina (análisis por provincia)	Modelo inicial entrenado

S10 (20/11–26/11)	Explicabilidad mediante SHAP y construcción inicial del dashboard	Hikari (SHAP), Alejandro (dashboard)	Modelo y métricas disponibles
S11 (27/11–03/12)	Integración, pruebas de extremo a extremo y documentación	Equipo	Dashboard funcional
S12 (04/12–10/12) · **Entrega NF4**	Entrega final, cierre del repositorio y presentación	Equipo	Todas las funcionalidades cerradas

https://github.com/cristinapuertolas-80/iFP-Piriscope/blob/main/docs/cronograma.pdf

Reparto de tareas: *el responsable principal de cada hito figura en la tabla anterior y sigue los roles del apartado 1; el equipo se apoya mutuamente ante bloqueos y las contribuciones individuales quedan trazadas en los Pull Requests.*

Riesgos técnicos: *tabla completa en el apartado 13; los tres más críticos para el plan son la fragmentación de EGIF, el desbalanceo de clases y la disponibilidad del FWI a nivel municipal.*

12. Estrategia de desarrollo

Flujo Git

No se realizarán cambios directamente sobre main.

Cada tarea se desarrollará en una rama independiente utilizando prefijos según el tipo de cambio:

- feat/ para nuevas funcionalidades.
- fix/ para correcciones.
- docs/ para documentación.
- chore/ para tareas de mantenimiento.

Las ramas se integrarán mediante Pull Requests, que se fusionan con squash en main; GitHub Actions ejecutará pytest en cada Pull Request.

Revisión de código

Todos los cambios pasan por Pull Request; se recomienda que los cambios relevantes sean revisados por al menos otro integrante del equipo antes de fusionarse con main.

Para cambios menores de documentación o mantenimiento también pasan por Pull Request; el criterio detallado está en CONTRIBUTING.md.

Validación del modelo

La validación se realizará mediante una partición temporal y geográfica, y no mediante una división aleatoria. Ambas particiones se definirán al inicio del proyecto, durante el EDA y antes de generar las variables derivadas y de ajustar hiperparámetros, para evitar que información del conjunto de validación influya en el diseño del modelo.

- **Partición temporal.** Se utilizarán los años anteriores para el entrenamiento y los años posteriores para la validación y el test, de modo que información de periodos posteriores nunca pueda influir en predicciones de periodos anteriores. El último año completo disponible se reservará como conjunto de test final. La división concreta de años se fijará una vez conocido el periodo común de las fuentes.
- **Partición geográfica.** Se reservará un subconjunto de municipios que no se utilizarán en ningún momento del entrenamiento, con el objetivo de comprobar si el modelo generaliza a municipios no vistos y no se limita a memorizar el comportamiento histórico de cada uno. La lista de municipios reservados se fijará con una semilla, se almacenará en el repositorio y no se modificará durante el proyecto. La reserva se estratificará por provincia y por frecuencia histórica de incendios, y se hará por bloques de municipios próximos (por ejemplo, por comarca o por estación AEMET asignada), porque municipios vecinos comparten clima y una reserva de municipios sueltos daría resultados optimistas.
- **Escenarios de evaluación.** Con ambas particiones se evaluarán tres escenarios:

Escenario	**Municipios**	**Periodo**	**Pregunta que responde**
A. Temporal	Vistos en el entrenamiento	Posterior	¿Funciona como sistema operativo?
B. Geográfico	Reservados (no vistos)	Mismo periodo del entrenamiento	¿Generaliza a otros municipios?
C. Temporal y geográfico	Reservados (no vistos)	Posterior	Caso más exigente

Como comprobación adicional, si el volumen de datos lo permite, se realizará una validación dejando una provincia fuera (*leave-one-province-out*) para analizar diferencias de comportamiento entre provincias.

- **Criterios de evaluación.** El modelo y el baseline FWI se compararán en cada escenario sobre exactamente los mismos datos, mediante Recall y AUC-PR, y desagregando por provincia. Dado que los días con incendio son escasos, las métricas de los escenarios B y C pueden ser inestables, por lo que se reportarán con intervalos de confianza (por ejemplo, mediante bootstrap). No se utilizarán identificadores de municipio ni coordenadas sin procesar como variables del modelo, para que este no pueda identificar municipios concretos. Una caída notable del rendimiento en los escenarios B o C no se considerará un fallo del proyecto, sino un resultado que se documentará como limitación del modelo.

Validación funcional

Cada historia del backlog se da por cerrada cuando cumple sus criterios de aceptación, que se revisan como lista de comprobación en el Pull Request. El dashboard se valida manualmente con los casos de uso de la descripción funcional (consulta por municipio, mapa, comparación con el FWI y explicación SHAP).

Testing

Se realizarán:

- Pruebas unitarias sobre funciones de generación de features, incluida la ausencia de información posterior a la fecha de predicción.
- Pruebas sobre la transformación y normalización de datos.
- Pruebas del cruce espacial y temporal (asignación de código INE y de estación a cada municipio).
- Pruebas sobre la generación de la variable objetivo.
- Smoke test para comprobar que el dashboard arranca correctamente y lee predicciones.parquet.

Reproducibilidad

El pipeline deberá poder ejecutarse de nuevo con un rango temporal diferente sin necesidad de modificar manualmente el código principal.

Las transformaciones realizadas sobre los datos y las decisiones relevantes del modelo estarán documentadas.

13. Riesgos técnicos actualizados

Riesgo	Impacto	Probabilidad	Plan de mitigación
Histórico de incendios de EGIF fragmentado por provincia o con diferencias de estructura entre periodos	Alto	Alta	Script de unificación reproducible que normaliza los ficheros, documenta las diferencias entre periodos y comprueba duplicados y recuentos frente a las estadísticas oficiales. Acotar el periodo si fuera necesario.
Dificultad para alinear espacialmente estaciones AEMET, municipios y datos de FWI	Alto	Media	Definir una metodología de asociación (estación más cercana con su distancia como indicador de calidad; centroide para el FWI) antes del entrenamiento y validarla sobre una muestra.
Disponibilidad limitada de determinados datos históricos de FWI	Alto	Media	Comprobar al inicio del proyecto el periodo común disponible y su resolución; ajustar el periodo de entrenamiento o calcular un

			baseline aproximado documentando la limitación.
Datos meteorológicos faltantes	Medio	Media	Analizar los valores ausentes y aplicar métodos de imputación documentados cuando proceda.
Límites, caídas o cambios en la API de AEMET	Medio	Media	Descargas por lotes con reintentos y caché en data/bronze; el histórico se descarga una sola vez.
Desbalance elevado entre días con y sin incendio	Alto	Alta	Utilizar pesos de clase y/o técnicas de balanceo cuando sean apropiadas y evaluar mediante Recall y AUC-PR.
El modelo no supera al baseline FWI	Alto	Media	Analizar el resultado como parte del objetivo comparativo del proyecto y priorizar la explicabilidad y el análisis de las diferencias.
Fuga de información temporal	Alto	Media	Utilizar particiones temporales y evitar features construidas con información posterior a la fecha de predicción (con test unitario).
Exceso de alcance por incorporación de demasiadas fuentes o modelos	Alto	Media	Mantener EGIF + AEMET + FWI como núcleo y dejar las fuentes y modelos avanzados como ampliaciones opcionales.
Pipeline de Big Data innecesariamente complejo	Medio	Media	Comenzar con pandas y utilizar PySpark únicamente si el volumen o los tiempos lo justifican.
Riesgo de interpretación incorrecta de las predicciones o de estigmatización de municipios	Medio	Media	Mostrar probabilidades, métricas y explicaciones; indicar que el sistema es una herramienta experimental de apoyo y no un sistema oficial de decisión.
El modelo no generaliza a municipios no vistos (memoriza el comportamiento histórico de cada municipio)	Alto	Media	Partición geográfica definida y congelada al inicio, con reserva por bloques de municipios próximos (comarca o estación asignada) y estratificada por

			provincia y frecuencia de incendios; exclusión de identificadores y coordenadas como variables; evaluación en los escenarios B y C con intervalos de confianza. Si el rendimiento cae, se documenta como limitación y se priorizan variables meteorológicas generales frente a variables específicas de cada municipio.
Cambios en códigos y nombres de municipios a lo largo del histórico (fusiones, cambios de denominación)	Medio	Media	Usar el catálogo vigente como referencia y una tabla de equivalencias a partir de las modificaciones anuales del INE; informe de partes no asignados y validación manual de una muestra. Si un municipio no puede reconciliarse de forma fiable, se excluye y se documenta.
No completar el proyecto en el plazo previsto	Alto	Media	Priorizar el MVP, cerrar primero el pipeline de datos y modelo, y reservar las últimas semanas para integración y documentación. Punto de control en las semanas 5-6 con recorte de alcance si hay retraso.

14. Repositorio del proyecto

El repositorio mantiene la estructura establecida durante NF1 y se amplía con los elementos necesarios para el desarrollo del proyecto.

Repositorio proyecto: https://github.com/cristinapuertolas-80/iFP-Piriscope

```
repo/
├ docs/                                  # Documentación del proyecto
│ ├ NF1_Presentacion_y_Viabilidad.pdf
│ ├ NF2_Documentacion_y_Diseno_Tecnico.pdf
│ ├ arquitectura.png
│ ├ municipios_reservados.csv
│ ├ tabla_equivalencias.csv
│ └ decisiones.md                       # Registro de decisiones técnicas
```

```
│
├ src/
│ ├ ingest/                    # Descarga e ingesta de las fuentes
│ ├ features/                  # Limpieza, cruce y variables derivadas
│ ├ ml/                        # Entrenamiento, evaluación e inferencia
│ ├ explainability/            # Explicaciones SHAP
│ └ dashboard/                 # Aplicación Streamlit
│
├ data/                       # Datos (no versionados)
│ ├ bronze/
│ ├ silver/
│ └ gold/
│
├ models/                     # Modelos serializados y versionados
├ enviroment/                 # Configuración del entorno
├ README.md
├ CONTRIBUTING.md
└ .gitignore
```

Los datos descargados de las fuentes externas no se incluirán directamente en el repositorio si su tamaño o condiciones de reutilización lo desaconsejan. Se documentará el procedimiento necesario para obtenerlos y reproducir el pipeline.

Los directorios data/bronze, data/silver y data/gold contendrán, respectivamente, los datos originales, los datos limpios en Parquet, y el dataset final con las predicciones. Ninguno se versiona (.gitignore); solo se conserva .gitkeep. Los modelos serializados se guardan en models/.

README.md recogerá la descripción del proyecto, los integrantes, la arquitectura resumida (con el diagrama), cómo ejecutar (instalación del entorno, API key de AEMET y comandos previstos del pipeline y del dashboard, marcando lo aún no implementado), las tecnologías y la estructura del repositorio.

CONTRIBUTING.md recogerá las normas de trabajo con Git, ramas, Pull Requests y revisión de cambios.

El documento decisiones.md se utilizará para registrar decisiones técnicas relevantes adoptadas durante el desarrollo.

Anexo A. Diccionario de variables

Los identificadores se guardan como texto; las fechas, como fecha; fecha_insert, como marca de tiempo en UTC; las medidas, como decimal. Al almacenarse en Parquet, las restricciones de nulos, claves foráneas y unicidad no las impone el formato, sino los tests del pipeline.

Variable	Tipo	Descripción
id_municipio	texto	Clave primaria de Municipio y clave foránea en el resto de tablas. Código INE vigente de 5 cifras (texto, para conservar los ceros iniciales); los históricos se reconcilian mediante la tabla de equivalencias. No es variable del modelo.
id_estacion_aemet	texto	Clave primaria de EstacionAemet y clave foránea en ObservacionMeteorologica. Indicativo de la estación en AEMET. No es variable del modelo.
id_obs_meteo	texto	Clave primaria. Derivada de id_municipio y fecha (p. ej. 15001_2020-05-14).
id_evento	texto	Clave primaria. Derivada de la campaña y el número de parte de EGIF (si el número se repite entre provincias, se añade la provincia; se comprueba en el EDA).
id_indicador_fwi	texto	Clave primaria. Derivada de id_municipio y fecha.
id_prediccion	texto	Clave primaria de Prediccion y clave foránea en las explicaciones SHAP. Derivada de id_municipio, fecha_objetivo y version_modelo (p. ej. 15001_2026-10-05_v1).
nombre	texto	Nombre oficial del municipio (en Municipio) o de la estación (en EstacionAemet).
provincia	texto	Provincia del municipio (A Coruña, Lugo, Ourense o Pontevedra); coincide con las dos primeras cifras de id_municipio. Se usa para estratificar la partición y desagregar métricas.
lat_centroide	numérico	Latitud del centroide del municipio (grados decimales). Sirve para asignar la estación, muestrear el FWI y dibujar el mapa; no es variable del modelo.

lon_centroide	numérico	Longitud del centroide del municipio (grados decimales). Mismo uso que lat_centroide.
latitud	numérico	Latitud de la estación AEMET (grados decimales).
longitud	numérico	Longitud de la estación AEMET (grados decimales).
altitud	numérico	Altitud de la estación AEMET (metros).
reservado	binario	1 si el municipio está reservado para la evaluación geográfica y nunca se usa en el entrenamiento; 0 en caso contrario.
fecha	fecha	Día D de la observación (se usa junto a id_municipio para derivar el id).
temperatura	numérico	Temperatura de la estación asignada (medida diaria homogénea a confirmar tras el EDA).
humedad_relativa	numérico	Humedad relativa de la estación asignada (medida diaria a confirmar tras el EDA).
viento	numérico	Velocidad del viento de la estación asignada (medida diaria a confirmar tras el EDA).
precipitacion	numérico	Precipitación acumulada diaria (mm).
racha_dias_secos	numérico	Días consecutivos sin precipitación relevante (variable derivada).
precip_acum_7d	numérico	Precipitación acumulada en los 7 días previos (variable derivada).
mes	categórico	Mes del año (variable derivada; captura la estacionalidad).
dist_estacion_km	numérico	Distancia entre el municipio y la estación asignada (indicador de calidad).
fwi	numérico	(Fire Weather Index): variable y baseline; el modelo se evaluará también sin FWI ni sus componentes para que la comparación no sea circular. También se copia en Prediccion para el dashboard.
ffmc	numérico	(Fine Fuel Moisture Code): humedad de los combustibles finos y muertos de la superficie.

dmc	numérico	(Duff Moisture Code): humedad de la capa orgánica superficial parcialmente descompuesta.
dc	numérico	(Drought Code): sequedad acumulada de las capas orgánicas profundas del suelo.
isi	numérico	(Initial Spread Index): potencial de propagación inicial según viento y humedad del combustible fino.
bui	numérico	(Buildup Index): disponibilidad de combustible, combinando DMC y DC.
fecha_deteccion	fecha	Fecha (y hora, si la fuente la incluye) de detección del incendio según EGIF. El día se usa para construir incendio_d1.
fecha_extincion	fecha	Fecha (y hora) de extinción según EGIF. Puede faltar en partes incompletos; no es variable del modelo (se conoce a posteriori).
causa	texto	Causa del incendio registrada en EGIF. Puede faltar; no es variable del modelo (solo se conoce una vez ocurrido el incendio).
superficie_forestal_ha	numérico	Superficie forestal afectada (ha) según el parte. No es variable del modelo (se conoce a posteriori); sirve para el análisis y el contraste con EFFIS.
coordenada_x	numérico	Coordenada X UTM del parte (m). Sirve para validar la asignación al municipio; no es variable del modelo.
coordenada_y	numérico	Coordenada Y UTM del parte (m). Mismo uso que coordenada_x.
huso	numérico	Huso UTM de las coordenadas del parte.
datum	texto	Sistema de referencia de las coordenadas del parte, según figure en EGIF.
fecha_objetivo	fecha	Día D+1 al que se refiere la predicción.
version_modelo	texto	Versión del modelo que genera la predicción (p. ej. v1).
probabilidad	numérico	Probabilidad estimada (0–1) de que el municipio registre al menos un parte de incendio en fecha_objetivo.

nivel_riesgo	categórico	Nivel de riesgo derivado de la probabilidad: bajo, medio o alto (umbrales fijados con el conjunto de validación tras el EDA).
variable	texto	Variable analizada para la explicación SHAP de una predicción.
valor_shap	numérico	Valor SHAP calculado sobre una variable de una predicción.
particion	categórico	Partición temporal de la fila según su fecha: entrenamiento, validación o test (el test es el último año completo). Se fija al inicio del proyecto y no se modifica.
incendio_d1 (objetivo)	binario	1 si el municipio registra al menos un parte de incendio (EGIF) con fecha de detección D+1; 0 en caso contrario.
fecha_insert	timestamp (fecha y hora)	Marca de tiempo en la que se carga el registro en la tabla. Sirve para trazabilidad; en Prediccion indica cuándo se generó la predicción. No es variable del modelo.

Las descripciones son provisionales: las variables definitivas se establecerán después del EDA y de comprobar la disponibilidad y homogeneidad temporal de las diferentes fuentes.

El identificador del municipio y las coordenadas no se utilizan como variables del modelo, para que este no pueda reconocer municipios concretos.

El entrenamiento utiliza únicamente filas con reservado = 0 y particion = entrenamiento.

Los escenarios de evaluación se obtienen filtrando por ambas columnas: A (temporal) = reservado = 0 y partición de validación o test; B (geográfico) = reservado = 1 y partición de entrenamiento; C (temporal y geográfico) = reservado = 1 y partición de validación o test.

Anexo B. Fuentes y enlaces

Fuente	Enlace	Para qué se usa
AEMET OpenData	https://opendata.aemet.es/centrodedescargas/inicio	Solicitar la API key y consultar datos meteorológicos
EGIF-MITECO, información	https://www.miteco.gob.es/es/biodiversidad/temas/incendios-forestales/estadisticas-datos.html	Estadística oficial y documentación
EGIF, buscador con exportación	https://servicio.mapa.gob.es/incendios/Search/Publico	Exportar los partes por provincia a Excel
EFFIS, datos y servicios	https://forest-fire.emergency.copernicus.eu/applications/data-and-services	Descarga del FWI y componentes
EFFIS, licencia de datos	https://forest-fire.emergency.copernicus.eu/about-effis/data-license	Condiciones de reutilización
INE, relación de municipios y códigos	https://www.ine.es/dynt3/metadatos/RespuestaDatos.html?oper=185	Códigos INE y nombres oficiales de los municipios
CNIG, centro de descargas	https://centrodedescargas.cnig.es/CentroDescargas/index.jsp	Límites municipales (recintos y líneas límite) en la sección de información geográfica de referencia